Namn: Jonny Frez

Maskininlärning för att förutsäga om en kandidat matchar ett jobb

Steg 1: Val av problem och dataset

I den här uppgiften valde jag att arbeta med ett problem där målet är att förutsäga om en person matchar ett jobb eller inte. Tanken var att använda information om en kandidat, till exempel utbildning, erfarenhet och olika kompetenser, för att låta en modell bedöma om personen passar för en viss tjänst.

Jag valde det här problemet eftersom det känns både relevant och intressant. Att försöka matcha rätt person med rätt jobb är något som används i verkligheten inom både rekrytering och karriärvägledning. Det kändes också extra passande eftersom jag själv arbetar med en sida där job matching är en viktig del. Därför tyckte jag att det var intressant att undersöka hur en enklare maskininlärningsmodell skulle kunna användas för att angripa ett liknande problem.

Datasetet jag använde innehåller information om kandidater och ett resultat som visar om personen matchar jobbet eller inte. Det gör datasetet lämpligt för uppgiften, eftersom modellen både får tillgång till indata och ett tydligt facit att lära sig från.

Det här är ett klassificeringsproblem, eftersom modellen ska avgöra vilken av två kategorier kandidaten tillhör: matchar jobbet eller matchar inte jobbet.
För att lösa uppgiften valde jag att använda modellen Random Forest. Jag valde den eftersom den passar bra för klassificeringsproblem, kan hantera flera variabler samtidigt och ofta fungerar bra utan att vara alltför komplicerad.

Steg 2: Förberedelse av data

När jag hade valt dataset började jag med att ladda in det i Python och undersöka hur det såg ut. Jag kontrollerade vilka kolumner som fanns, hur många rader datasetet innehöll och om det fanns några saknade värden. Det var ett viktigt första steg för att förstå datat innan modellen tränades.

Efter det förberedde jag datat för maskininlärning. Eftersom modellen behöver arbeta med tydliga indata valde jag ut de variabler som var mest relevanta för uppgiften. I det här fallet handlade det om utbildning, erfarenhet och olika kompetenser. Kolumnen som visar om kandidaten matchar jobbet eller inte användes som målvariabel, alltså det som modellen skulle försöka förutsäga.

Alla värden i datasetet var redan numeriska, vilket gjorde att någon större omvandling inte behövdes. Jag kunde också se att det inte fanns några saknade värden, vilket gjorde datat enklare att arbeta vidare med.

För att få en bättre överblick skapade jag även en visualisering. Den hjälpte mig att förstå hur datat var fördelat och gav en tydligare bild av innehållet innan träningen påbörjades.

Steg 3: Val av modell och träning

För att lösa uppgiften valde jag alltså att använda Random Forest. Anledningen var att modellen fungerar bra för klassificering och är relativt lätt att använda i ett mindre projekt som detta. Den är också användbar när man vill se om det finns tydliga mönster i datat.

Innan modellen tränades delade jag upp datasetet i två delar: träningsdata och testdata. Träningsdatan användes för att modellen skulle kunna lära sig mönster i datat, medan testdatan användes för att kontrollera hur bra modellen fungerade på nya exempel som den inte hade sett tidigare. Jag använde 80 procent av datat till träning och 20 procent till test.

När uppdelningen var klar tränades modellen på träningsdatan. Det innebär att modellen fick använda informationen om kandidaternas egenskaper för att försöka lära sig skillnaden mellan personer som matchar ett jobb och personer som inte gör det.

Efter träningen användes modellen för att göra förutsägelser på testdatan. På så sätt gick det att jämföra modellens svar med det faktiska utfallet och se hur bra den fungerade.

Steg 4: Utvärdering av modellen

Modellen utvärderades genom att dess förutsägelser på testdatan jämfördes med det verkliga utfallet. På så sätt gick det att se hur bra modellen var på att skilja mellan kandidater som matchar jobbet och kandidater som inte gör det. Eftersom detta är ett klassificeringsproblem använde jag måtten accuracy, precision, recall och F1-score för att bedöma modellens prestanda. Accuracy visar hur stor andel av modellens förutsägelser som blev rätt totalt sett. Precision visar hur ofta modellen hade rätt när den förutsåg en match. Recall visar hur stor andel av de verkliga matchningarna som modellen lyckades hitta. F1-score ger en sammanvägd bild av precision och recall.

Resultatet visade att modellen fick en accuracy på cirka 91,7 %, vilket betyder att den gjorde rätt förutsägelse i de flesta fallen. För klassen som motsvarar kandidater som matchar jobbet var både precision och recall 0,94, medan motsvarande värden för kandidater som inte matchade jobbet var 0,88. Det visar att modellen fungerade bra på testdatan och klarade av att skilja mellan de två klasserna på ett tydligt sätt.

Samtidigt är det viktigt att komma ihåg att datasetet i uppgiften var förenklat. I en verklig situation hade problemet troligen varit mer komplext, med fler variabler och fler osäkra fall. Resultatet visar därför främst att modellen fungerade bra på det dataset som användes i uppgiften, men inte nödvändigtvis att den direkt skulle fungera lika bra i ett verkligt rekryteringssystem.

Om modellen skulle förbättras ytterligare hade man kunnat testa andra inställningar, använda fler relevanta variabler eller jämföra med fler modeller. Man hade också kunnat använda ett större och mer verklighetsnära dataset för att få en mer realistisk utvärdering.

Etisk reflektion

En viktig sak att tänka på i det här projektet är att modellen inte bör ses som ett färdigt svar på om en person passar för ett jobb eller inte. Den bygger bara på det data som finns i datasetet och kan därför missa sådant som också är viktigt i verkligheten.

Eftersom datasetet i uppgiften är förenklat finns det en risk att resultatet ger en alltför enkel bild av hur job matching fungerar. I verkligheten påverkas sådana bedömningar av många fler faktorer, och det finns också en risk att vissa grupper inte representeras rättvist i datat.

Det finns även en risk att en modell som verkar fungera bra får människor att lita för mycket på resultatet. Därför tycker jag att en sådan modell bara bör användas som stöd och inte som ensam grund för beslut. En människa bör alltid göra den slutliga bedömningen.